Multimodal en multiscale AI voor de voorspelling en mechanistische interpretatie van toxicologische effecten

Onderzoeksvoorstel & Motivatie Promotieonderzoek (Hogeschool Utrecht) • Lectoraat Innovative Testing

1. Systeembiologische AI in de Toxicologie

De afgelopen decennia, met een enorme vlucht in de laatste tien jaar, zijn AI en biologie steeds dichter naar elkaar toe gegroeid. Dat is onder andere te danken aan de enorme hoeveelheid data in publieke repositories zoals Gene Expression Omnibus, Zenodo, UniProt en de Protein Data Bank (Barrett et al., 2013; European Organisation for Nuclear Research, 2013; UniProt Consortium, 2023; Satija et al., 2015; Berman et al., 2000). Waar de complexiteit van biologische data voorheen vaak een struikelblok vormde (Ching et al., 2018), maken recente AI-doorbraken het mogelijk om extreem grote, heterogene datasets te duiden (He et al., 2016; Vaswani et al., 2017; Jumper et al., 2021; Chithrananda et al., 2020; Wu et al., 2021; Maziarka et al., 2020). Binnen de toxicologie richten grootschalige initiatieven zoals Tox21 in de VS (National Institutes of Health, z.d.) en het Utrechtse Ombion (Ombion CPBT, z.d.) zich hiermee op New Approach Methodologies (NAMs): dierproefvrije, data-gedreven testen. Daarbij onderscheiden we in vitro NAM's (biologische modelsystemen zoals cellen, organoids of eiwitten) en in silico NAM's (computermodellen en AI). Juist vanwege de heterogeniteit van deze data is AI bij uitstek geschikt voor kennisintegratie in de chemische risicobeoordeling (Luechtefeld & Hartung, 2026), zoals het Europese ONTOX-project recent liet zien door met Agentic AI bestaande kennis te bundelen voor nieuwe stoffen (Vinken et al., 2021).

Reductionisme versus multi-directionele en emergente dynamiek

Een pijler binnen NAM is het uitwerken van Adverse Outcome Pathways (AOP's en kwantitatieve qAOP's), waarbij onder andere Large Language Models (LLM's) helpen om literatuur samen te voegen (Corradi et al., 2024). De kracht van een klassieke AOP ligt in de reductionistische, lineaire redenering: van een Molecular Initiating Event (MIE) via oplopende biologische schalen (molecuul → cel → weefsel → orgaan) naar een schadelijk effect (adverse outcome). Toch schiet een puur lineaire blik tekort. Niet elk effect verloopt van klein naar groot; asbest grijpt bijvoorbeeld primair in op weefselniveau (Donaldson et al., 2010). Voor zulke multi-directionele oorzaak-gevolgrelaties bieden bredere systeemnetwerken zoals Physiological maps (Staumont et al., 2025) een noodzakelijke aanvulling op lineaire AOP-ketens.

Hogere-orde patronen en homeostatische attractor states

Bovendien ontstaan sommige schadelijke effecten pas op hogere orde (grotere schaal) als emergente eigenschap. Cortical Spreading Depression (CSD, bekend van migraine-aura's) is een Reaction-Diffusion-proces (Turing, 1952) en bio-elektrisch netwerkfenomeen (Levin, 2023): stress veroorzaakt weliswaar kalium en glutamaatafgifte in cellen (MIE), maar of dit overslaat naar omliggende cellen hangt af van de weefselstructuur. Vanuit AI bezien is dit emergence in Complex Systems, waarbij hogere-orde patronen niet louter uit de regels van losse deeltjes te verklaren zijn (Wolfram, 2002). Of een stof daadwerkelijk schade aanricht, hangt daarnaast af van de blootstellingscontext — het exposoom (Wild, 2005) — en de terugkoppeling tussen alle organisatieniveaus tot aan het DNA (Noble, 2012). Een gezonde cel vangt continue prikkels op binnen een stabiele, homeostatische attractor state (Kauffman, 1993), terwijl ziekte (zoals kanker) een pathologische attractor vormt. Een stof is dus niet binair giftig, maar geeft afhankelijk van dosis en duur en biologische context een kans om de cel naar een andere (pathologische) staat te brengen (Maertens, 2025). In het toxicologische veld wordt dit principe toegepast als probabilistic chemical risk assessment.

2. Synthese, Veldrelevantie en Persoonlijke Positionering

Resumerend: De brug tussen systeembiologie en multimodal en multiscale AI

Omdat toxiciteit geen simpel lineair proces is, maar een samenspel van schalen, emergente patronen en cellulaire attractor states, richt dit promotieonderzoek zich op het ontwikkelen en valideren van multimodal (type data, zoals genexpressie, celmorfologie of elektrofysica) en multiscale (abstractielaag, van eiwit en cel tot weefselnetwerk) AI-methoden. De centrale hypothese is dat de integratie van complementaire in vitro NAM-data met op chemische structuur gebaseerde AI modellen blootlegt wanneer een cellulaire perturbatie nog binnen de gezonde, adaptieve homeostase valt, en wanneer het systeem kantelt naar een daadwerkelijke adverse outcome.

Relevantie vanuit het veld

Waar binnen single-scale en single-modality AI al grote sprongen zijn gemaakt (Jumper et al., 2021; Way et al., 2022), staat multimodal en multiscale analyse in de biologie nog in de kinderschoenen door de hoge kosten en technische complexiteit van gecombineerde experimenten. Toch laten zowel recente studies (Chen et al., 2023; Dincer et al., 2024; Vandereyken et al., 2024) als toonaangevende bedrijven zoals het Nederlands-Zwitserse Cradle de enorme potentie zien (Cradle Bio, z.d.; 10x Genomics, z.d.; Owkin, z.d.; Sapient, z.d.). De wetenschappelijke uitdaging ligt nu in het slim combineren van bestaande data en structuurmodellen met nieuwe algoritmes die zelfs bij beperkte experimentele metingen betrouwbare voorspellingen doen voor nieuwe chemische stoffen.

Versterken van lectoraat, onderwijs en beroepspraktijk

Binnen het lectoraat Innovative Testing, waar het zwaartepunt op laboratoriumonderzoek ligt, biedt mijn AI-expertise de kans om een volwaardige theoretische en in silico onderzoekslijn uit te bouwen (bijvoorbeeld met Graph Transformers), in nauwe samenwerking met het lectoraat lectAI. Deze modellen geven richting aan nieuw labonderzoek, terwijl onze eigen in vitro data directe validatie mogelijk maken. Als ontwikkelaar en coördinator van twee van de drie AI-semesters bij het Institute for ICT (HU) zie ik bovendien hoe belangrijk het is om toekomstige AI-professionals op te leiden op het snijvlak van biologie en AI. Vanuit dit promotieonderzoek sla ik een brug naar bio-informatica door realistische casussen en methodologische verdieping in te brengen in de Bachelor AI richting, Master Human-Centered AI (HCAI, Life Sciences track) en ICT-minoren zoals Data Science.

Motivatie, ervaring en pre-promotietraject

Ik ben enorm geïnteresseerd in cognitie en gebruik mijn AI-expertise als paradigma. Hoewel cellulaire programma's, evolutionaire algoritmes en fractals tijdens mijn studie AI al mijn favoriete onderwerpen waren, heb ik pas de afgelopen jaren ontdekt hoe fascinerend biologische cellen zijn. Mijn sterkste wetenschappelijke punten zijn het vormen van analogieën tussen verschillende lagen van abstractie en het strategisch kijken naar de toekomst. Mijn onderzoekservaring omvat een masterscriptie (45 EC), twee jaar onderzoek bij Philips Research naar zelflerende systemen en zeven jaar begeleiding van circa 20 studenten per jaar bij praktijkgericht onderzoek. Ik weet al veel over de algoritmische realiteit, nu nog de organische! Daarom doorloop ik van februari tot september een pre-promotietraject om mij via literatuurstudie de toxicologische kaders eigen te maken en preliminaire AI-aannames kritisch te toetsen voordat het traject officieel start.

3. Werkplan: Vraagstelling, Strategie en Werkpakketten

Centrale vraagstelling & drie wetenschappelijke deelvragen

Hoofdvraag: *In hoeverre kan multimodal en multiscale AI, door experimentele NAM-data te integreren met chemische structuurinformatie, onderscheid maken tussen adaptieve (homeostatische) en potentieel schadelijke cellulaire perturbaties, en daarmee de voorspelling van adverse outcomes voor nieuwe chemische stoffen verbeteren?*

1. Welke complementaire informatie leveren verschillende NAM-modaliteiten en biologische schalen (inclusief emergente hogere-orde patronen) over chemisch geïnduceerde verschuivingen in cellulaire attractor states?

2. In hoeverre verbetert de integratie van deze multimodale experimentele informatie met structure-based AI (zoals ToxTransformer) de voorspelling van toxicologische effecten voor ongeziene chemische stoffen?
3. In hoeverre kunnen de gevonden multiscale patronen worden gekoppeld aan bestaande AOP's én bredere Physiological maps om relaties tussen key events en adverse outcomes te kwantificeren?

Onderzoeksstrategie

Chemische blootstelling veroorzaakt veranderingen op verschillende niveaus: transcriptomics toont moleculaire genexpressie, high-content beeldvorming legt celmorfologie vast en functionele assays meten de impact op cel- en weefselnetwerken. Afzonderlijk laten deze modaliteiten echter niet altijd zien of een cel succesvol herstelt binnen haar homeostatische attractor state of kantelt naar pathologie. In dit onderzoek breiden we bestaande structure-based AI-modellen — met ToxTransformer als technisch startpunt — uit met representaties van deze moleculaire, morfologische en functionele NAM-data. Door de voorspellende kracht en interpreteerbaarheid systematisch te vergelijken met unimodale en puur op structuur gebaseerde modellen, toetsen we zowel de generaliseerbaarheid naar nieuwe stoffen als de mechanistische verrijking van kwantitatieve AOP-netwerken (qAOP's) en Physiological maps. Het onderzoek is opgebouwd uit een voorbereidende fase (WP0) en vier samenhangende werkpakketten (WP1–WP4):

Werkpakket	Kernactiviteiten & Methodiek	Theoretische verankering	Beoogd Resultaat
WP0 *Pre-promotietraject (Feb – Sep)*	Literatuurstudie, het eigen maken van toxicologische kaders en NAM-concepten, en het kritisch toetsen van preliminaire AI-aannames.	Slaat een inhoudelijke brug tussen AI en toxicologie; legt de theoretische basis voor AOP's en multimodale data-integratie.	Aangescherpt theoretisch kader en getoetste hypothese voor aanvang van het officiële promotietraject.
WP1 *Data-selectie & Harmonisatie*	Selectie en standaardisatie van heterogene NAM-datasets op chemische identiteit, concentratie, blootstellingsduur, modelsysteem en metadata.	Borgt de blootstellingscontext (dosis/tijd) die bepaalt of een perturbatie adaptief of schadelijk wordt; koppeling aan AOP-key events.	Reproduceerbare, FAIR georganiseerde collectie van multimodale NAM datasets.
WP2 *Multimodale & Multiscale AI*	Uitbreiding van ToxTransformer met moleculaire, morfologische en functionele embeddings; vergelijking van fusie-strategieën en omgang met missing modalities.	Combineert schalen om zowel directe moleculaire effecten als emergente hogere-orde netwerkpatronen in één modelrepresentatie te vangen.	Gevalideerde multimodale AI-architectuur vergeleken met unimodale en structuur-baselines.
WP3 *Mechanistische Interpretatie*	Analyse van geleerde AI-patronen; strikt onderscheid tussen statistische correlatie, voorspellende waarde en experimenteel bewezen causaliteit.	Toetst of het model homeostatische vs. pathologische attractor states herkent en niet-lineaire relaties in qAOP's en Physiological maps kwantificeert.	Mechanistisch inzichtelijke AI-voorspellingen en gekwantificeerde key event relaties.
WP4 *Evaluatie & Validering*	Evaluatie op onafhankelijke validatiesets: testen van de voorspellende prestaties voor nieuwe chemische stoffen bij wisselende combinaties van beschikbare experimentele NAM-data (van uitsluitend structuurinformatie tot volledige multimodale metingen).	Operationaliseert probabilistic chemical risk assessment en de grenzen van de generaliseerbaarheid over biologische en chemische contexten heen.	Richtlijn voor het gebruik van multimodale AI-methoden in de praktijk van de toxicologische risicobeoordeling.

4. Demonstratiecases: Emergentie en Homeostase in de Praktijk

Om te bewijzen dat de ontwikkelde AI-methodologie zowel lineaire AOP-ketens als niet-lineaire, emergente systeemprocessen kan duiden, evalueren we de werkpakketten aan de hand van twee complementaire toxicologische demonstratiecases waarvoor rijke NAM-data en mechanistische kaders beschikbaar zijn:

Casus 1: Ontwikkelingsneurotoxiciteit (DNT)

Systeemfocus — Emergente hogere-orde patronen: Verstoring van de neuro-ontwikkeling uit zich bij uitstek op netwerkniveau, vergelijkbaar met de eerder besproken emergente dynamiek in exciterende weefsels. Eerder werk toont aan dat gecombineerde transcriptomics, metabolomics en elektrofysiologische metingen inzicht geven in verstoorde neuronale netwerkvorming (Marable et al., 2022). Door deze drie modaliteiten te integreren met chemische structuur in ToxTransformer, onderzoeken we hoe moleculaire en metabole prikkels doorwerken naar emergente elektrofysiologische netwerkactiviteit.

Casus 2: Levertoxiciteit (Steatose & Cholestase)

Systeemfocus — Attractor states & Physiological maps: De lever houdt lipiden en galzuurprocessen actief in een homeostatische attractor state. We nemen twee AOP's als basis: LXR-activatie richting steatose (AOP 34) en BSEP-remming richting cholestase (AOP 27). Met transcriptomics, proteomics, metabolomics en high-content imaging uit menselijke levercelmodellen (Rodrigues et al., 2018; Müller et al., 2023) modelleren we wanneer adaptieve compensatie binnen het fysiologische netwerk faalt en kantelt naar leverschade.

In beide demonstratiecases vergelijken we onze multimodal en multiscale modellen met puur structuur gebaseerde en unimodale baselines (WP2/WP4) en toetsen we in hoeverre de geleerde representaties bekende key events én niet-lineaire terugkoppelingen kwantificeren (WP3). Zo vormen DNT en levertoxiciteit een directe empirische toetssteen voor de theoretische uitgangspunten uit sectie 1.

5. Onderwijsintegratie, FAIR-Infrastructuur en HU-Zwaartepunten

Dit promotieonderzoek is vanaf de start ontworpen als een open, reproduceerbaar ecosysteem waarin studenten van de Master HCAI en de ICT-minoren (waaronder Data Science) actief participeren. Studenten werken aan afgebakende deelvraagstukken binnen WP1 t/m WP4: van dataharmonisatie en het reproduceren van gepubliceerde baselines tot het evalueren van deelmodellen. Om te garanderen dat studentbijdragen cumulatief en wetenschappelijk robuust zijn, werken we met een gestandaardiseerde open-source onderzoeksinfrastructuur voorzien van strikt versiebeheer, gedocumenteerde datapijplijnen en FAIR-principes.

Hiermee verankert het project zich direct in de HU-zwaartepunten Samen Digitaal en Samen Gezond. Enerzijds krijgen studenten én ICT-docenten een realistisch, grootschalig R&D-oefenterrein om te leren wat er nodig is om als AI-professional in het bio-domein te opereren. Anderzijds verwerven de laboratoriumonderzoekers binnen Innovative Testing toepasbare AI-kennis om hun in vitro experimenten slimmer te ontwerpen en te duiden.

6. Literatuurlijst

1. 10x Genomics. (z.d.). Single cell and spatial solutions. Geraadpleegd op 25 oktober 2026.
2. Barrett, T., Wilhite, S. E., Ledoux, P., Evangelista, C., Kim, I. F., Tomashevsky, M., Marshall, K. A., Phillippy, K. H., Sherman, P. M., Holko, M., Yefanov, A., Lee, H., Zhang, N., Robertson, C. L., Serova, N., Davis, S., & Soboleva, A. (2013). NCBI GEO: Archive for functional genomics data sets—update. *Nucleic Acids Research*, 41(D1), D991–D995. https://doi.org/10.1093/nar/gks1193
3. Berman, H. M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T. N., Weissig, H., Shindyalov, I. N., & Bourne, P. E. (2000). The Protein Data Bank. *Nucleic Acids Research*, 28(1), 235–242. https://doi.org/10.1093/nar/28.1.235
4. Chen, S., Bileschi, M. L., Belanger, D., & Colwell, L. J. (2023). Multi-modal representations for protein property prediction. *Bioinformatics*, 39(1), btac812. https://doi.org/10.1093/bioinformatics/btac812
5. Ching, T., Himmelstein, D. S., Beaulieu-Jones, B. K., Kalinin, A. A., Do, B. T., Way, G. P., Ferrero, E., Agapow, P. M., Zietz, M., Hoffman, M. M., Xie, W., Rosen, G. L., Lancia, B. J., Greene, C. S., & Xie, L. (2018). Opportunities and obstacles for deep learning in biology and medicine. *Journal of the Royal Society Interface*, 15(141), 20170387. https://doi.org/10.1098/rsif.2017.0387
6. Chithrananda, S., Grand, G., & Ramsundar, B. (2020). CheBERTa: Large-scale self-supervised pretraining for molecular property prediction (arXiv:2010.09885). *arXiv*. https://doi.org/10.48550/arXiv.2010.09885
7. Corradi, M., Luechtefeld, T., de Haan, A. M., Pieters, R., Freedman, J. H., Vanhaecke, T., Vinken, M., & Teunis, M. (2024). The application of natural language processing for the extraction of mechanistic information in toxicology. *Frontiers in Toxicology*, 6, 1393662. https://doi.org/10.3389/ftox.2024.1393662
8. Cradle Bio. (z.d.). AI-driven protein engineering platform. Geraadpleegd op 25 oktober 2026.
9. Dincer, A. B., Janizek, J. D., & Lee, S. I. (2024). Multi-modal machine learning in precision medicine. *Nature Reviews Genetics*, 25(3), 180–198. https://doi.org/10.1038/s41576-023-00664-4
10. Donaldson, K., Poland, C. A., & Murphy, F. A. (2010). Asbestos, carbon nanotubes and the pleural mesothelium: A review of the hypothesis regarding the role of long fibre retention in the parietal pleura, inflammation and mesothelioma. *Particle and Fibre Toxicology*, 7(1), Article 5. https://doi.org/10.1186/1743-8977-7-5
11. European Organisation for Nuclear Research. (2013). Zenodo: Research shared. CERN.
12. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90
13. Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Žídek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., … Hassabis, D. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873), 583–589. https://doi.org/10.1038/s41586-021-03819-2
14. Kauffman, S. A. (1993). *The Origins of Order: Self-Organization and Selection in Evolution* (pp. 173–235). Oxford University Press.
15. Levin, M. (2023). Bioelectric signaling: Regenerative biology and computational medicine. *Cell*, 186(11), 2280–2300. https://doi.org/10.1016/j.cell.2023.04.020
16. Luechtefeld, T., & Hartung, T. (2026). Artificial intelligence in chemical risk assessment. *ALTEX - Alternatives to Animal Experimentation*.
17. Maertens, A. (2025). Probabilistic chemical risk assessment: Transitioning from deterministic to probabilistic paradigms in toxicology. *ALTEX - Alternatives to Animal Experimentation*, 42(3), 413–434. https://orbi.uliege.be/bitstream/2268/334718/1/altex_2025_3_413_434_t4_Maertens.pdf
18. Marable, C. A., Frank, C. L., Seim, R. F., Hester, S., Henderson, W. M., Chorley, B., & Shafer, T. J. (2022). Integrated omic analyses identify pathways and transcriptomic regulators associated with chemical alterations of in vitro neural network formation. *Toxicological Sciences*, 186(1), 118–133. https://doi.org/10.1093/toxsci/kfab151
19. Maziarka, Ł., Danel, T., Mucha, S., Rataj, K., Tabor, J., & Jastrzębski, S. (2020). Molecule Attention Transformer. *Machine Learning: Science and Technology*, 1(3), Article 035010. https://doi.org/10.1088/2632-2153/ab9b58
20. Müller, F. A., Stamou, M., Englert, F. H., Frenzel, O., Diedrich, S., Suter-Dick, L., Wambaugh, J. F., & Sturla, S. J. (2023). In vitro to in vivo extrapolation and high-content imaging for simultaneous characterization of chemically induced liver steatosis and markers of hepatotoxicity. *Archives of Toxicology*, 97(6), 1701–1721. https://doi.org/10.1007/s00204-03490-8
21. National Institutes of Health. (z.d.). Tox21: Toxicology in the 21st century. U.S. Department of Health and Human Services. Geraadpleegd op 25 oktober 2026.
22. Noble, D. (2012). A theory of biological relativity: No privileged level of causation. *Interface Focus*, 2(1), 55–64.
23. Ombion CPBT. (z.d.). Ombion project: Data-driven toxicity testing without animals. Center for Physiological Based Testing. Geraadpleegd op 25 oktober 2026.
24. Owkin. (z.d.). AI-powered precision medicine and drug discovery. Geraadpleegd op 25 oktober 2026.
25. Rodrigues, R. M., Kollipara, L., Chaudhari, U., Sachinidis, A., Zahedi, R. P., Sickmann, A., Kopp-Schneider, A., Jiang, X., Keun, H., Hengstler, J., Oorts, M., Annaert, P., Hoeben, E., Gijbels, E., De Kock, J., Vanhaecke, T., Rogiers, V., & Vinken, M. (2018).

Omics-based responses induced by bosentan in human hepatoma HepaRG cell cultures. *Archives of Toxicology*, 92(6), 1939–1952. https://doi.org/10.1007/s00204-018-2214-z

26. Sapient. (z.d.). Mass spectrometry-based metabolomics and proteomics. Geraadpleegd op 25 oktober 2026.
27. Satija, R., Farrell, J. A., Gennert, D., Schier, A. F., & Regev, A. (2015). Spatial reconstruction of single-cell gene expression data. *Nature Biotechnology*, 33(5), 495–502.
28. Staumont, B., Ladeira, L., Gamba, A., Heusinkveld, H. J., Piersma, A., Fritsche, E., Masereeuw, R., Vanhaecke, T., Teunis, M., Luechtefeld, T. H., Hartung, T., Jover, R., Vinken, M., & Geris, L. (2025). Mapping physiology: A systems biology approach for the development of alternative methods in toxicology. *ALTEX - Alternatives to Animal Experimentation*, 42(2), 301–307. https://doi.org/10.14573/altex.2412241
29. Turing, A. M. (1952). The chemical basis of morphogenesis. *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences*, 237(641), 37–72. https://doi.org/10.1098/rstb.1952.0012
30. UniProt Consortium. (2023). UniProt: The Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, 51(D1), D523–D531.
31. Vandereyken, K., Sifrim, A., Thienpont, B., & Voet, T. (2024). Methods and applications for single-cell multi-omics. *Nature Reviews Genetics*, 25(1), 15–37. https://doi.org/10.1038/s41576-023-00643-9
32. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 5998–6008).
33. Vinken, M., Benfenati, E., Busquet, F., Castell, J., Clevert, D.-A., de Kok, T. M., Dirven, H., Fritsche, E., Geris, L., Gozalbes, R., Hartung, T., Jennen, D., Jover, R., Kandarova, H., Kramer, N., Krul, C., Luechtefeld, T., Masereeuw, R., Roggen, E., … Piersma, A. H. (2021). Safer chemicals using less animals: Kick-off of the European ONTOX project. *Toxicology in Vitro*, 75, Article 105212. https://doi.org/10.1016/j.tiv.2021.105212
34. Way, G. P., Kost-Alimova, M., Dančík, V., Belfiore, A., Chandler, K. B., Singh, S., & Carpenter, A. E. (2022). Predicting cell health phenotypes using image-based profiling. *Cell Genomics*, 2(11), Article 100207. https://doi.org/10.1016/j.xgen.2022.100207
35. Wild, C. P. (2005). Complementing the genome with an "exposome": The outstanding challenge of environmental exposure measurement in molecular epidemiology. *Cancer Epidemiology, Biomarkers & Prevention*, 14(8), 1847–1850. https://doi.org/10.1158/1055-9965.EPI-05-0456
36. Wolfram, S. (2002). *A new kind of science* (pp. 737–750). Wolfram Media.
37. Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., & Pande, V. (2021). MoleculeNet: A benchmark for molecular machine learning. *Chemical Science*, 9(2), 513–530.